


A Fundação Invisível: Transformando Dados Brutos em Decisões Confiáveis

Limpeza, Preparação e
Qualidade dos Dados
com Pandas



A ilusão do trabalho em análise de dados

O que fazemos



- Entender problemas de negócio.
- Organizar dados confiáveis.
- Extrair indicadores.

Gestor pergunta: "Onde devo investir mais? Qual canal performa melhor? Por que a receita caiu?"


O que entregamos



- Respostas para decisões táticas e estratégicas.
- Informação visual, interativa e publicável.

A regra dos 80% e a anatomia do sucesso

Dashboard Bonito



Limpeza,
Padronização,
Tipagem,
Tratamento
de Nulos

“Dashboards profissionais quase sempre **falham** por causa de **dados mal preparados**.”

- 80% do tempo de um projeto real é gasto na limpeza.
- O dashboard final é apenas a ponta do iceberg.
- O trabalho submerso sustenta a validade da análise.

Dashboards profissionais falham por causa de dados mal preparados

Um dashboard bonito com dados ruins não reduz o erro, ele **aumenta o risco da decisão**.

Gambiarras silenciosas escondem problemas graves e custam caro.

Margem de Lucro: Infinito ⚠️




Exemplos do Custo da Sujeira:

- Margem calculada com receita zerada gera indicadores inválidos.
- Datas salvas como texto quebram gráficos temporais e escondem sazonalidades.
- Categorias duplicadas criam distorções no ranking.

O checklist de um dataset "Clean"

Para estar pronto para análise, o dataset deve obrigatoriamente:

- 
- ✓ Tipos corretos (datas como datas, números como float/int)
 - ✓ Colunas padronizadas e bem nomeadas
 - ✓ Livre de duplicidades nocivas
 - ✓ Valores ausentes (missing) tratados de forma consciente
 - ✓ Enriquecido com variáveis derivadas úteis
 - ✓ Totalmente **reprodutível** (processo no Pandas, sem Excel manual)

Batalha 1: A tirania dos tipos de dados

Erros de tipo geram análises incorretas. O computador precisa entender a natureza do dado.
Datas não são texto: Essenciais para séries temporais e sazonalidade.

O problema do texto (String):

'100' + '200' = '100200'
'100200'

O poder do número (Float/Int):

100 + 200 = 300
100 + 200 = 300



```
df['data'] = pd.to_datetime(df['data'], errors='coerce')

df['data'] = pd.to_datetime(df['data'], errors='coerce')
df['receita'] = pd.to_numeric(df['receita'], errors='coerce')
```

Batalha 2: O enigma dos valores ausentes (Nulos)

Valores ausentes (missing) não são erros automáticos. Eles representam informação incompleta que conta uma história.

Estratégias comuns de tratamento:

- **Remover** (**dropna**): Apenas quando são poucos e não críticos.
- **Preencher** (**fillna**): Com valor padrão (**0**) ou estatística (**mediana**).
- **Manter**: Quando o próprio vazio é uma informação útil.

Inspecionando o problema:

```
`df.isna().sum()`
```

A regra de ouro dos valores ausentes

Nunca trate um valor ausente sem justificar o ‘porquê’ no seu código.

- Substituir receitas ausentes por zero vai derrubar drasticamente o seu **Ticket Médio**.
 - Substituir pela média vai suavizar **anomalias reais**.
 - Decisões de limpeza no **Pandas** devem ser documentadas com **comentários**.
- Profissionais explicam as transformações.

Batalha 3: O ataque dos clones (Duplicidades)

O Pandas facilita a remoção, mas a decisão é do analista de negócio.

O Dilema:

- É um erro de sistema (dupla inserção) ou uma compra real repetida pelo mesmo cliente?
- Remover pedidos legítimos altera e corrompe diretamente os **KPIs de Receita e Lucro** que o diretor vai visualizar.

ID	Data	Produto	Valor
1001	2023-10-27	Laptop X1	\$1200
1001	2023-10-27	Laptop X1	\$1200



```
df.drop_duplicates()
```

Subindo de nível: Criação de variáveis derivadas


Não basta apenas limpar as falhas; é preciso enriquecer a fundação (Feature Engineering).

Variáveis derivadas destravam novas análises e filtros poderosos para os dashboards.

Exemplos críticos criados a partir do dataset original:

- Extração temporal: ano e mês a partir da data bruta.
- Formatação de período: Ano-mês em string para agrupar gráficos.
- Categorizações estratégicas: Classificar itens como Margem Alta ou Margem Baixa.

Transformação de Variáveis (Feature Engineering)



Construindo a lente do negócio no Pandas

A Margem de Lucro não existe no dataset original. É você quem deve criá-la.

Antes

receita	lucro
...	...
...	...
...	...



Depois

receita	lucro	margem_lucro
...	...	...
...	...	...
...	...	...

```
df['ano'] = df['data'].dt.year  
df['margem_lucro'] = df['lucro'] / df['receita']
```



Cuidado Técnico: Tratamento para divisões por zero gerando valores infinitos (np.inf).


A Seleção Final: Menos é mais

Nem toda coluna do dataset original merece ir para o seu dashboard final.

- Selecionar colunas reduz o custo de processamento, otimiza memória e facilita a leitura.

A Pergunta de Corte:

Quais colunas são estritamente necessárias para responder às perguntas de negócio?



	A	B	B	C	D	E	F	G	H	I	J
1			data	uf	canal	categoria	receita	lucro			
2											
3											
4											
5											
6											
7											
8											
9											
10											
11											
12											
13											

Python | pandas

```
df_dash = df[['data', 'uf', 'canal', 'categoria', 'receita', 'lucro']].copy()
```

O Selo de Qualidade: Exportando a base "Clean"

Criar um arquivo limpo e fisicamente isolado traz benefícios cruciais:

- Separa os dados brutos inalterados dos dados já preparados.
- Facilita o reaproveitamento nas próximas aulas.
- Garante a reprodutibilidade absoluta do projeto.




vendas_brasil_clean.csv

```
df.to_csv('data/vendas_brasil_clean.csv', index=False)
```

O impacto invisível no seu Portfólio Final

A qualidade do trabalho realizado no Pandas hoje define a precisão do dashboard interativo de amanhã.

- Seu código é seu portfólio.
- Não existe código reutilizável sobre dados mal estruturados.
- Retrabalho na análise é sinal de falha na estruturação.



Missão Prática: Case Varejo Brasil

O Desafio Imediato:

- 1) **Abra o notebook** da Aula 3.
- 2) **Converta corretamente** a coluna de data.
- 3) **Crie as colunas** ano, mês e margem.
- 4) **Mapeie e trate** valores ausentes e duplicidades.
- 5) **Gere a exportação final** vendas_brasil_clean.csv.

Registro Reflexivo:

Documente no notebook quais **decisões de limpeza** você tomou e por quê.

